

Clasificación de eventos del bosón de Higgs mediante modelos de Machine Learning

Lina María Montoya Zuluaga
Universidad de Antioquia
Medellín, Colombia
linam.montoya@udea.edu.co

Diego Armando Muñoz Carvajal
Universidad de Antioquia
Medellín, Colombia
diego.munozc@udea.edu.co

Resumen—Este trabajo aborda una tarea de clasificación binaria entre eventos de señal y fondo asociados al bosón de Higgs usando el dataset HIGGS del repositorio UCI. El proyecto compara distintos modelos de Machine Learning sobre un conjunto de datos simulado de gran escala, con el objetivo de evaluar qué tan bien separan eventos de interés físico frente a eventos de fondo. En esta primera entrega se describe el problema y se revisan dos trabajos que usan esta misma base como referencia para comparar modelos de clasificación; las secciones de metodología, resultados y conclusiones se desarrollan en la entrega final.

Index Terms—bosón de Higgs, clasificación binaria, aprendizaje supervisado, HIGGS, AUC-ROC

I. INTRODUCCIÓN

La física de partículas de alta energía trabaja con un problema de clasificación complejo: distinguir, entre una gran cantidad de colisiones producidas por aceleradores como el Gran Colisionador de Hadrones (LHC) del CERN, cuáles podrían estar asociadas al bosón de Higgs y cuáles corresponden a procesos de fondo. Baldi et al. [2] formulan este reto como un problema de discriminación señal-fondo en el que la partícula de interés no se observa directamente, pues decae casi instantáneamente y solo deja trazas indirectas en los detectores a través de sus productos de desintegración.

El presente trabajo aborda este reto utilizando el dataset HIGGS del repositorio UCI Machine Learning Repository [3]. El objetivo principal es construir y evaluar modelos de clasificación capaces de separar eventos de señal —colisiones simuladas en las que se produce un bosón de Higgs— y eventos de fondo. Este conjunto de datos tiene dos tipos de características. En términos simples, las de bajo nivel resultan de las partículas observables en el detector, es decir, son mediciones de cantidades físicas directas, mientras que las de alto nivel son combinaciones de las variables de bajo nivel diseñadas por físicos para preservar la información dinámica de las variables. Esta diferencia ayuda a entender la discusión planteada por Baldi et al. [2] sobre el papel de las características diseñadas manualmente, pero en este proyecto la comparación inicial de modelos se plantea sobre las 28 variables disponibles (21 variables de bajo nivel y 7 de alto nivel).

II. DESCRIPCIÓN DEL PROBLEMA

El bosón de Higgs es una partícula fundamental del Modelo Estándar cuya detección experimental requiere analizar grandes volúmenes de eventos generados en colisiones de protones a alta energía. En el problema físico real, la tarea no consiste en observar directamente la partícula, sino en identificar, a partir de variables cinemáticas medidas o derivadas, si un evento corresponde a un proceso de *señal* asociado a la producción del bosón de Higgs o a un proceso de *fondo* perteneciente a la física estándar sin producción del Higgs, esto debido a que es una partícula que decae con suma rapidez y por ello se detecta a partir de las partículas en las que se desintegra tras la colisión.

Este tipo de tarea resulta adecuado para técnicas de Machine Learning porque involucra una gran cantidad de ejemplos, relaciones no lineales entre variables y fronteras de decisión difíciles de formular manualmente. En particular, los modelos de clasificación pueden aprender diferencias entre ejemplos ya etiquetados y ayudar a separar eventos de interés frente a eventos de fondo.

Con base en estas consideraciones, se seleccionó el dataset **HIGGS** para el proyecto del curso Modelos y Simulación II, con el fin de analizar el desempeño de diferentes modelos de Machine Learning frente a este tipo de problemas de clasificación. La documentación de UCI describe este dataset como generado mediante simulaciones Monte Carlo, con aproximadamente 11 millones de eventos, 28 variables de entrada y una etiqueta binaria de clase [3]. La primera columna corresponde al **label**, donde **1** indica un evento de señal y **0** un evento de fondo. Además, Baldi et al. [2] distinguen dos grupos de variables: las primeras 21 representan propiedades cinemáticas de bajo nivel asociadas a observables de detector dentro de la simulación, mientras que las últimas 7 corresponden a características de alto nivel derivadas por físicos a partir de las anteriores para facilitar la discriminación entre clases. La Tabla I resume el significado de esos dos grupos.

Como todas las variables son numéricas, no fue necesario codificar alguna. Además, la documentación de UCI reporta que no hay valores faltantes [3], lo cual coincide con el análisis exploratorio realizado; por lo cual no fue necesario realizar un proceso de imputación. Para hacer viable el procesamiento

Cuadro I
VARIABLES DEL DATASET HIGGS AGRUPADAS POR TIPO. ADAPTADO DE [2] Y DE LA DOCUMENTACIÓN DEL REPOSITORIO UCI [3].

Tipo	Variables	Significado
Bajo nivel (21)	p_T, η, ϕ del leptón	Momento transverso y dirección del electrón o muón.
	p_T, η, ϕ de cuatro <i>jets</i>	Momento y dirección de los chorros de partículas.
	b -tag de cuatro <i>jets</i>	Indicador de si un <i>jet</i> proviene de un quark b .
	$E_T^{\text{miss}}, \phi^{\text{miss}}$	Energía transversa faltante asociada a neutrinos u otras partículas invisibles.
Alto nivel (7)	m_{jj}, m_{jjj}	Masas invariantes de combinaciones de <i>jets</i> .
	m_{lv}, m_{jlv}	Masas que reconstruyen el bosón W leptónico y el sistema W + <i>jet</i> .
	$m_{bb}, m_{Wbb}, m_{WWbb}$	Masas que reconstruyen el bosón de Higgs ligero y los estados intermedios de la cadena de desintegración.

en Google Colab, en el desarrollo experimental del proyecto se utilizó una submuestra estratificada de 500 000 eventos, preservando la proporción entre clases del conjunto original.

Aunque en la realidad experimental el problema es altamente desbalanceado —Baldi et al. [2] mencionan apenas unos cientos de bosones de Higgs por cada 10^{11} colisiones del LHC—, el dataset utilizado presenta clases aproximadamente balanceadas. Esto no contradice el contexto físico: en simulaciones Monte Carlo, las muestras de señal y fondo pueden generarse de forma independiente y luego ponderarse con pesos de sección eficaz para el análisis estadístico final [2]. En el contexto del dataset HIGGS de UCI, este balance permite que el entrenamiento se concentre en aprender las diferencias entre las distribuciones cinemáticas de ambos procesos.

El problema abordado se formula como una tarea de **aprendizaje supervisado de clasificación binaria**. Esta decisión se justifica porque cada muestra del dataset tiene una etiqueta conocida generada por simulación, lo que permite entrenar modelos a partir de pares entrada-salida. En la práctica, el modelo recibe las 28 variables de un evento y debe estimar si ese evento corresponde a señal o fondo. La distinción entre variables de bajo y alto nivel se usa para interpretar mejor la composición del dataset y los trabajos previos, no para cambiar la tarea central de clasificación. Esta formulación es coherente tanto con la estructura del dataset como con la literatura asociada al dataset HIGGS de UCI: Baldi et al. [2] y Azhari et al. [1] comparan clasificadores supervisados usando principalmente AUC-ROC y *accuracy*.

Bajo esta formulación, el enfoque del equipo es comparar varios tipos de modelos supervisados sobre el mismo problema, en lugar de apostar por un único modelo. Esto incluye al menos un modelo paramétrico lineal como línea base, un modelo no paramétrico, ensambles de árboles de decisión, una red neuronal y una máquina de vectores de soporte, siguiendo lo que la guía del curso solicita en fases posteriores. Esta

selección se complementa con los antecedentes revisados, que comparan redes neuronales, modelos lineales y ensambles de árboles sobre el mismo dataset [1], [2]. Más adelante se explica qué modelos se escogieron y cómo se ajustaron sus hiperparámetros. Como métrica principal se usa AUC-ROC por ser la métrica común en los trabajos revisados, acompañada de *accuracy* para mantener comparabilidad con la literatura [1], [2] y de F1-score como métrica complementaria del proyecto. La motivación de extender el trabajo de Baldi et al. con modelos modernos de clasificación, como variantes de *gradient boosting* y redes profundas con regularización, se retoma en la entrega final del proyecto.

III. ESTADO DEL ARTE

La revisión bibliográfica se centró en trabajos que abordan el mismo problema de este proyecto: la clasificación binaria entre eventos de señal y fondo usando el dataset **HIGGS** de UCI. Para esta primera entrega se tomaron dos referencias principales: una se enfoca en el desempeño de redes profundas y la otra revisa modelos clásicos en un entorno distribuido con PySpark.

Baldi et al. [2] es la referencia central porque consolida el dataset HIGGS como banco de prueba para comparar clasificadores supervisados en física de altas energías. Los autores comparan redes neuronales profundas de cinco capas con *dropout* frente a redes poco profundas, regresión logística y *boosted decision trees* de TMVA, usando AUC-ROC y *accuracy* como métricas principales. Para este proyecto, lo más útil de ese trabajo no es únicamente el AUC reportado, sino que muestra que las redes profundas pueden aprender, a partir de variables de bajo nivel, información similar a la que aportan las variables de alto nivel diseñadas por físicos. En su protocolo experimental reportan AUC cercana a 0,880 con variables de bajo nivel y 0,885 con el conjunto completo de variables, sobre un conjunto de prueba separado de 500 000 eventos simulados.

Azhari et al. [1] retoman el mismo problema desde otra preocupación: entrenar y comparar modelos clásicos en un entorno PySpark para datos de gran escala. En lugar de profundizar en arquitecturas neuronales, evalúan regresión logística, árbol de decisión, *random forest* y *gradient boosted tree*, también con AUC y *accuracy*. En este artículo, el mejor resultado reportado corresponde al *gradient boosted tree*, con $\text{AUC} \approx 0,705$ y $\text{accuracy} \approx 0,706$. Esa diferencia no significa simplemente que un modelo sea mejor que otro; también muestra que el protocolo experimental, el preprocesamiento y los recursos de entrenamiento influyen considerablemente en el resultado final.

La métrica AUC-ROC, usada en ambos trabajos, corresponde al área bajo la curva ROC, que relaciona la tasa de verdaderos positivos con la tasa de falsos positivos al variar el umbral de decisión. Formalmente, $\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$, donde valores cercanos a 1 indican mejor discriminación. Esta métrica se elige porque no depende de un umbral fijo y es robusta frente al ligero desbalance entre clases del dataset. Baldi et al. [2] también discuten métricas propias de física

de altas energías, como la eficiencia de señal a un rechazo de fondo fijo y la significancia de descubrimiento. En esta entrega no se adoptan como métricas del proyecto porque requieren fijar umbrales de decisión y, en el caso de la significancia, asumir tasas o pesos físicos esperados para señal y fondo.

Con base en estos trabajos, decidimos usar AUC-ROC como métrica principal y comparar modelos modernos con los resultados reportados en la literatura. La idea es revisar si modelos de clasificación distintos a los comparados originalmente en 2014 permiten acercarse o superar el desempeño reportado por Baldi et al. usando recursos de cómputo más limitados. Sin embargo, esos valores se toman como referencia contextual y no como una meta exactamente equivalente, porque una comparación estricta requeriría replicar el mismo particionamiento de datos, preprocesamiento, arquitectura y condiciones de entrenamiento.

REFERENCIAS

- [1] Mourad Azhari, Abdallah Abarda, Badia Ettaki, Jamal Zerouaoui, and Mohamed Dakkon. Higgs boson discovery using machine learning methods with pyspark. *Procedia Computer Science*, 170:1141–1146, 2020.
- [2] Pierre Baldi, Peter Sadowski, and Daniel Whiteson. Searching for exotic particles in high-energy physics with deep learning. *Nature Communications*, 5:4308, 2014.
- [3] Daniel Whiteson. Higgs. UCI Machine Learning Repository, 2014.