

Clasificación de eventos del bosón de Higgs mediante modelos de Machine Learning

Lina María Montoya Zuluaga
Universidad de Antioquia
Medellín, Colombia
linam.montoya@udea.edu.co

Diego Armando Muñoz Carvajal
Universidad de Antioquia
Medellín, Colombia
diego.munozc@udea.edu.co

Resumen—Este trabajo aborda una tarea de clasificación binaria entre eventos de señal y fondo asociados al bosón de Higgs usando el dataset HIGGS del repositorio UCI. El proyecto compara distintos modelos de Machine Learning sobre un conjunto de datos simulado de gran escala, con el objetivo de evaluar qué tan bien separan eventos de interés físico frente a eventos de fondo. En esta primera entrega se describe el problema y se revisan dos trabajos que usan esta misma base como referencia para comparar modelos de clasificación; las secciones de metodología, resultados y conclusiones se desarrollan en la entrega final.

Index Terms—bosón de Higgs, clasificación binaria, aprendizaje supervisado, HIGGS, AUC-ROC

I. INTRODUCCIÓN

La física de partículas de alta energía trabaja con un problema de clasificación complejo: distinguir, entre una gran cantidad de colisiones producidas por aceleradores como el Gran Colisionador de Hadrones (LHC) del CERN, cuáles podrían estar asociadas al bosón de Higgs y cuáles corresponden a procesos de fondo. Baldi et al. [2] formulan este reto como un problema de discriminación señal-fondo en el que la partícula de interés no se observa directamente, pues decae casi instantáneamente y solo deja trazas indirectas en los detectores a través de sus productos de desintegración.

El presente trabajo aborda este reto utilizando el dataset HIGGS del repositorio UCI Machine Learning Repository [4]. El objetivo principal es construir y evaluar modelos de clasificación capaces de separar eventos de señal —colisiones simuladas en las que se produce un bosón de Higgs— y eventos de fondo. Este conjunto de datos tiene dos tipos de características. En términos simples, las de bajo nivel resultan de las partículas observables en el detector, es decir, son mediciones de cantidades físicas directas, mientras que las de alto nivel son combinaciones de las variables de bajo nivel diseñadas por físicos para preservar la información dinámica de las variables. Esta diferencia ayuda a entender la discusión planteada por Baldi et al. [2] sobre el papel de las características diseñadas manualmente, pero en este proyecto la comparación inicial de modelos se plantea sobre las 28 variables disponibles (21 variables de bajo nivel y 7 de alto nivel).

II. DESCRIPCIÓN DEL PROBLEMA

El bosón de Higgs es una partícula fundamental del Modelo Estándar cuya detección experimental requiere analizar grandes volúmenes de eventos generados en colisiones de protones a alta energía. En el problema físico real, la tarea no consiste en observar directamente la partícula, sino en identificar, a partir de variables cinemáticas medidas o derivadas, si un evento corresponde a un proceso de *señal* asociado a la producción del bosón de Higgs o a un proceso de *fondo* perteneciente a la física estándar sin producción del Higgs, esto debido a que es una partícula que decae con suma rapidez y por ello se detecta a partir de las partículas en las que se desintegra tras la colisión.

Este tipo de tarea resulta adecuado para técnicas de Machine Learning porque involucra una gran cantidad de ejemplos, relaciones no lineales entre variables y fronteras de decisión difíciles de formular manualmente. En particular, los modelos de clasificación pueden aprender diferencias entre ejemplos ya etiquetados y ayudar a separar eventos de interés frente a eventos de fondo.

Con base en estas consideraciones, se seleccionó el dataset **HIGGS** para el proyecto del curso Modelos y Simulación II, con el fin de analizar el desempeño de diferentes modelos de Machine Learning frente a este tipo de problemas de clasificación. La documentación de UCI describe este dataset como generado mediante simulaciones Monte Carlo, con aproximadamente 11 millones de eventos, 28 variables de entrada y una etiqueta binaria de clase [4]. La primera columna corresponde al **label**, donde **1** indica un evento de señal y **0** un evento de fondo. Además, Baldi et al. [2] distinguen dos grupos de variables: las primeras 21 representan propiedades cinemáticas de bajo nivel asociadas a observables de detector dentro de la simulación, mientras que las últimas 7 corresponden a características de alto nivel derivadas por físicos a partir de las anteriores para facilitar la discriminación entre clases. La Tabla I resume el significado de esos dos grupos.

Como todas las variables son numéricas, no fue necesario codificar alguna. Además, la documentación de UCI reporta que no hay valores faltantes [4], lo cual coincide con el análisis exploratorio realizado; por lo cual no fue necesario realizar un proceso de imputación. Para hacer viable el procesamiento

Cuadro I
VARIABLES DEL DATASET HIGGS AGRUPADAS POR TIPO. ADAPTADO DE [2] Y DE LA DOCUMENTACIÓN DEL REPOSITORIO UCI [4].

Tipo	Variables	Significado
Bajo nivel (21)	p_T, η, ϕ del leptón	Momento transverso y dirección del electrón o muón.
	p_T, η, ϕ de cuatro <i>jets</i>	Momento y dirección de los chorros de partículas.
	b -tag de cuatro <i>jets</i>	Indicador de si un <i>jet</i> proviene de un quark b .
	$E_T^{\text{miss}}, \phi^{\text{miss}}$	Energía transversa faltante asociada a neutrinos u otras partículas invisibles.
Alto nivel (7)	m_{jj}, m_{jjj}	Masas invariantes de combinaciones de <i>jets</i> .
	m_{lv}, m_{jlv}	Masas que reconstruyen el bosón W leptónico y el sistema W + <i>jet</i> .
	$m_{bb}, m_{Wbb}, m_{WWbb}$	Masas que reconstruyen el bosón de Higgs ligero y los estados intermedios de la cadena de desintegración.

en Google Colab, en el desarrollo experimental del proyecto se utilizó una submuestra estratificada de 500 000 eventos, preservando la proporción entre clases del conjunto original.

Aunque en la realidad experimental el problema es altamente desbalanceado —Baldi et al. [2] mencionan apenas unos cientos de bosones de Higgs por cada 10^{11} colisiones del LHC—, el dataset utilizado presenta clases aproximadamente balanceadas. Esto no contradice el contexto físico: en simulaciones Monte Carlo, las muestras de señal y fondo pueden generarse de forma independiente y luego ponderarse con pesos de sección eficaz para el análisis estadístico final [2]. En el contexto del dataset HIGGS de UCI, este balance permite que el entrenamiento se concentre en aprender las diferencias entre las distribuciones cinemáticas de ambos procesos.

El problema abordado se formula como una tarea de **aprendizaje supervisado de clasificación binaria**. Esta decisión se justifica porque cada muestra del dataset tiene una etiqueta conocida generada por simulación, lo que permite entrenar modelos a partir de pares entrada-salida. En la práctica, el modelo recibe las 28 variables de un evento y debe estimar si ese evento corresponde a señal o fondo. La distinción entre variables de bajo y alto nivel se usa para interpretar mejor la composición del dataset y los trabajos previos, no para cambiar la tarea central de clasificación. Esta formulación es coherente tanto con la estructura del dataset como con la literatura asociada al dataset HIGGS de UCI: Baldi et al. [2] y Azhari et al. [1] comparan clasificadores supervisados usando principalmente AUC-ROC y *accuracy*.

Bajo esta formulación, el enfoque del equipo es comparar varios tipos de modelos supervisados sobre el mismo problema, en lugar de apostar por un único modelo. Esto incluye al menos un modelo paramétrico lineal como línea base, un modelo no paramétrico, ensambles de árboles de decisión, una red neuronal y una máquina de vectores de soporte, siguiendo lo que la guía del curso solicita en fases posteriores. Esta

selección se complementa con los antecedentes revisados, que comparan redes neuronales, modelos lineales y ensambles de árboles sobre el mismo dataset [1], [2]. Más adelante se explica qué modelos se escogieron y cómo se ajustaron sus hiperparámetros. Como métrica principal se usa AUC-ROC por ser la métrica común en los trabajos revisados, acompañada de *accuracy* para mantener comparabilidad con la literatura [1], [2] y de F1-score como métrica complementaria del proyecto. La motivación de extender el trabajo de Baldi et al. con modelos modernos de clasificación, como variantes de *gradient boosting* y redes profundas con regularización, se retoma en la entrega final del proyecto.

III. ESTADO DEL ARTE

La revisión bibliográfica se centró en trabajos que abordan el mismo problema de este proyecto: la clasificación binaria entre eventos de señal y fondo usando el dataset **HIGGS** de UCI. Para esta primera entrega se tomaron dos referencias principales: una se enfoca en el desempeño de redes profundas y la otra revisa modelos clásicos en un entorno distribuido con PySpark.

Baldi et al. [2] es la referencia central porque consolida el dataset HIGGS como banco de prueba para comparar clasificadores supervisados en física de altas energías. Los autores comparan redes neuronales profundas de cinco capas con *dropout* frente a redes poco profundas, regresión logística y *boosted decision trees* de TMVA, usando AUC-ROC y *accuracy* como métricas principales. Para este proyecto, lo más útil de ese trabajo no es únicamente el AUC reportado, sino que muestra que las redes profundas pueden aprender, a partir de variables de bajo nivel, información similar a la que aportan las variables de alto nivel diseñadas por físicos. En su protocolo experimental reportan AUC cercana a 0,880 con variables de bajo nivel y 0,885 con el conjunto completo de variables, sobre un conjunto de prueba separado de 500 000 eventos simulados.

Azhari et al. [1] retoman el mismo problema desde otra preocupación: entrenar y comparar modelos clásicos en un entorno PySpark para datos de gran escala. En lugar de profundizar en arquitecturas neuronales, evalúan regresión logística, árbol de decisión, *random forest* y *gradient boosted tree*, también con AUC y *accuracy*. En este artículo, el mejor resultado reportado corresponde al *gradient boosted tree*, con $\text{AUC} \approx 0,705$ y $\text{accuracy} \approx 0,706$. Esa diferencia no significa simplemente que un modelo sea mejor que otro; también muestra que el protocolo experimental, el preprocesamiento y los recursos de entrenamiento influyen considerablemente en el resultado final.

La métrica AUC-ROC, usada en ambos trabajos, corresponde al área bajo la curva ROC, que relaciona la tasa de verdaderos positivos con la tasa de falsos positivos al variar el umbral de decisión. Formalmente, $\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$, donde valores cercanos a 1 indican mejor discriminación. Esta métrica se elige porque no depende de un umbral fijo y es robusta frente al ligero desbalance entre clases del dataset. Baldi et al. [2] también discuten métricas propias de física

de altas energías, como la eficiencia de señal a un rechazo de fondo fijo y la significancia de descubrimiento. En esta entrega no se adoptan como métricas del proyecto porque requieren fijar umbrales de decisión y, en el caso de la significancia, asumir tasas o pesos físicos esperados para señal y fondo.

Con base en estos trabajos, decidimos usar AUC-ROC como métrica principal y comparar modelos modernos con los resultados reportados en la literatura. La idea es revisar si modelos de clasificación distintos a los comparados originalmente en 2014 permiten acercarse o superar el desempeño reportado por Baldi et al. usando recursos de cómputo más limitados. Sin embargo, esos valores se toman como referencia contextual y no como una meta exactamente equivalente, porque una comparación estricta requeriría replicar el mismo particionamiento de datos, preprocesamiento, arquitectura y condiciones de entrenamiento.

IV. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

IV-A. Configuración Experimental

Dado el volumen del dataset original (11 millones de eventos), se realizó un submuestreo estratificado de 500 000 eventos mediante `train_test_split` con el parámetro `stratify`, preservando la distribución original de clases (53 % señal / 47 % fondo). El análisis exploratorio confirmó la ausencia de valores faltantes, por lo que no fue necesario ningún proceso de imputación. Todas las variables son continuas y de tipo `float64`, por lo que tampoco se requirió codificación categórica.

La submuestra se dividió en tres conjuntos mediante splits estratificados sucesivos: entrenamiento (70 %, 350 000 muestras), validación (15 %, 75 000 muestras) y prueba (15 %, 75 000 muestras), preservando el balance de clases en los tres conjuntos.

La selección de hiperparámetros se realizó mediante búsqueda en malla (*grid search*) evaluada sobre el conjunto de validación. Una vez identificada la mejor configuración para cada modelo, se estimó su capacidad de generalización mediante validación cruzada estratificada con $k = 5$ pliegues sobre el conjunto de entrenamiento, reportando la media y el intervalo de confianza al 95 % ($\mu \pm 2\sigma$ sobre los cinco pliegues). La evaluación final se realizó sobre el conjunto de prueba, que no participó en ninguna etapa de selección ni ajuste.

Los modelos que requieren variables en escala comparable (SVM, KNN, Regresión Logística, Red Neuronal) fueron estandarizados con media cero y desviación estándar unitaria mediante `StandardScaler`, ajustado exclusivamente sobre los datos de entrenamiento de cada pliegue y aplicado sobre validación y prueba, evitando fuga de información. Los modelos basados en árboles con particionamiento nativo (Random Forest, XGBoost, LightGBM, CatBoost, HistGradientBoosting) son invariantes a la escala y no requirieron este paso. Dado el costo computacional de KNN con grandes volúmenes de datos, este modelo fue entrenado sobre una submuestra estratificada de 100 000 eventos del conjunto de entrenamiento.

La métrica principal de evaluación es el **AUC-ROC**, definida como $AUC = \int_0^1 TPR(FPR) dFPR$, donde valores cercanos a 1 indican mayor poder discriminativo. Esta métrica se seleccionó por ser estándar en los trabajos de referencia sobre el dataset HIGGS [1], [2] y por ser robusta frente al leve desbalance entre clases. Como métricas secundarias se reportan *accuracy*, *F1-score*, *precision* y *recall* sobre el conjunto de prueba.

La Tabla II resume los diez modelos evaluados y la malla de hiperparámetros explorada para cada uno. Se incluyeron modelos de *gradient boosting* (XGBoost, LightGBM, CatBoost, HistGradientBoosting) dado que los trabajos revisados en el estado del arte los señalan como los clasificadores más competitivos en este problema [1]. Adicionalmente, se evaluó un ensamble de tipo *stacking* que combina los cuatro modelos de boosting con Random Forest como modelos base y Regresión Logística como meta-aprendiz.

Cuadro II
MODELOS EVALUADOS Y MALLA DE HIPERPARÁMETROS ANALIZADA.
KNN FUE ENTRENADO SOBRE UNA SUBMUESTRA ESTRATIFICADA DE 100 000 EVENTOS. EL STACKING UTILIZA CONFIGURACIÓN FIJA SIN GRID SEARCH.

Modelo	Tipo	Hiperparámetro	Valores explorados
Reg. Logística	Paramétrico	C	{0,01; 0,1; 1; 10; 100}
KNN	No paramétrico	k	{3; 5; 10; 15; 25}
Random Forest	Ensamble	$n_estimators$ max_depth	{50; 100; 200} {5; 10; 20; None}
Red Neuronal (MLP)	Red neuronal	$hidden_layer_sizes$ $learning_rate_init$	{(64), (128), (64,64), (128,64)} {0,001; 0,01}
SVM (LinearSVC)	Margen máximo	C $kernel$	{0,1; 1; 10} lineal
XGBoost	Boosting	$learning_rate$ max_depth $subsample$	{0,05; 0,1; 0,2} {5; 8; 12} {0,7; 1,0}
LightGBM	Boosting	$learning_rate$ num_leaves $subsample$	{0,05; 0,1; 0,2} {31; 63; 127; 255} {0,7; 1,0}
CatBoost	Boosting	$learning_rate$ $depth$ $l2_leaf_reg$	{0,05; 0,1; 0,2} {5; 8; 12} {1; 3; 10}
HistGradientBoosting	Boosting	$learning_rate$ max_leaf_nodes $l2_regularization$	{0,05; 0,1; 0,2} {31; 63; 127; None} {0; 0,5}
Stacking (5 base + LR)	Ensamble	Configuración fija: HistGB + XGBoost + LightGBM + CatBoost + RF $\rightarrow$ LogisticRegression($C = 1$)	

IV-B. Resultados del Entrenamiento de Modelos

A continuación se presentan los resultados de la experimentación para cada uno de los seis modelos evaluados. Para cada modelo se analiza el efecto de los hiperparámetros sobre el AUC-ROC en validación, y se reportan los resultados finales en entrenamiento (validación cruzada con $k = 5$), validación y prueba. La Tabla III al final de esta sección consolida los resultados de todos los modelos para facilitar la comparación.

IV-B1. Regresión Logística: La Regresión Logística se evaluó variando el parámetro de regularización inversa $C \in \{0,01; 0,1; 1; 10; 100\}$. Como se observa en la Fig. 1, el AUC en validación aumenta de forma pronunciada entre $C = 0,01$ y $C = 0,1$, y se estabiliza en 0.6865 a partir de $C = 1$, lo que indica que la penalización de regularización no es determinante más allá de ese valor y que el modelo alcanza su capacidad máxima con regularización moderada. El mejor modelo ($C = 100$) reportó AUC-CV de $0,685 \pm 0,002$, AUC de validación de 0.687 y AUC de prueba de 0.685, con F1 de 0.688 y *accuracy* de 0.643. La consistencia entre las

tres particiones confirma ausencia de sobreajuste, aunque el desempeño global es limitado, comportamiento esperado dado el carácter lineal del modelo frente a las relaciones no lineales del problema.




Figura 1. AUC-ROC en validación de la Regresión Logística en función del parámetro de regularización C . El desempeño se estabiliza a partir de $C = 0,1$, lo que indica saturación de la capacidad del modelo.

IV-B2. KNN: El clasificador KNN fue evaluado sobre 100 000 muestras variando el número de vecinos $k \in \{3, 5, 10, 15, 25\}$. La Fig. 2 muestra que el AUC en validación aumenta de forma monótona con k : de 0.643 con $k = 3$ a 0.704 con $k = 25$, lo que refleja que vecindades más amplias reducen el efecto del ruido en las fronteras de decisión. El mejor modelo ($k = 25$) obtuvo AUC-CV de $0,701 \pm 0,002$, AUC de validación de 0.704, AUC de prueba de 0.706, F1 de 0.701 y *accuracy* de 0.652. La tendencia creciente con k sugiere que valores mayores podrían aportar ganancias adicionales, aunque a costo computacional considerablemente más alto, dado que KNN requiere calcular distancias contra todos los ejemplos de entrenamiento en tiempo de inferencia.




Figura 2. AUC-ROC en validación del KNN en función del número de vecinos k . El desempeño crece monótonamente, con la mayor ganancia entre $k = 3$ y $k = 10$.

IV-B3. Random Forest: El Random Forest se evaluó en una malla de $3 \times 4 = 12$ combinaciones entre $n_estimators \in \{50; 100; 200\}$ y $max_depth \in \{5; 10; 20; \text{None}\}$. La Fig. 3 muestra que la profundidad tiene un impacto considerablemente mayor que el número de árboles: pasar de $max_depth = 5$ a profundidad sin restricción (None) supone una ganancia de 6.1 puntos porcentuales en AUC (de 0.753 a 0.814), mientras que incrementar $n_estimators$ de 50 a 200 aporta menos de 0.4 puntos en cualquier nivel de profundidad. Cabe desta-

car que $max_depth = 20$ produce resultados prácticamente idénticos a la profundidad irrestricta (0.8132 frente a 0.8141 con $n_estimators = 200$), lo que sugiere que los árboles alcanzan su capacidad máxima antes de agotar las particiones disponibles en este dataset. La mejor configuración ($n_estimators = 200$, $max_depth = \text{None}$) alcanzó AUC-CV de $0,810 \pm 0,003$, AUC de validación de 0.814 y AUC de prueba de 0.812, con F1 de 0.751 y *accuracy* de 0.734.




Figura 3. AUC-ROC en validación del Random Forest para distintas combinaciones de $n_estimators$ y max_depth . La profundidad irrestricta domina en todos los niveles de $n_estimators$.

IV-B4. Red Neuronal (MLP): La red neuronal fue evaluada en 8 configuraciones combinando cuatro arquitecturas con dos tasas de aprendizaje. La Fig. 4 muestra que la profundidad de la arquitectura es el factor dominante: las configuraciones de dos capas superan en todos los casos a las de una sola capa, independientemente de la tasa de aprendizaje. Este resultado es coherente con la naturaleza del problema: las variables del dataset HIGGS incluyen tanto observables de detector de bajo nivel como masas invariantes de alto nivel derivadas de combinaciones no lineales de aquellos, por lo que una segunda capa oculta permite al modelo construir representaciones intermedias que capturan esa jerarquía de abstracción. Una arquitectura de una sola capa, en cambio, debe aprender directamente la frontera de decisión final desde las entradas crudas, lo que limita su capacidad expresiva para este tipo de relaciones.

Dentro de las arquitecturas de dos capas, $lr = 0,001$ produce un mejor resultado que $lr = 0,01$, pero en las arquitecturas de una capa esta tendencia no se mantiene de forma consistente. En general, las diferencias entre configuraciones son modestas (AUC entre 0.80 y 0.83), lo que sugiere que una vez garantizada la suficiente profundidad, el MLP no es muy sensible a estos hiperparámetros dentro del rango explorado. Esto es típico en problemas donde la dificultad proviene de la estructura de los datos más que de la escasez de capacidad del modelo: añadir más neuronas o ajustar la tasa de aprendizaje aporta rendimientos decrecientes una vez superado un umbral mínimo de complejidad.

La mejor configuración — capas ocultas (128,64) con $lr = 0,001$ — alcanzó AUC de validación de 0.829. El

mejor modelo obtuvo AUC-CV de $0,820 \pm 0,006$, AUC de validación de 0.829 y AUC de prueba de 0.826, con F1 de 0.764 y *accuracy* de 0.746. El intervalo de confianza más amplio respecto a los demás modelos ($\pm 0,006$ frente a $\pm 0,002-0,004$) no refleja inestabilidad del modelo sino una propiedad estructural del entrenamiento de redes neuronales: la inicialización aleatoria de pesos introduce variabilidad entre pliegues que los modelos deterministas como los árboles de decisión no tienen, y que en este caso es acotada y aceptable.




Figura 4. AUC-ROC en validación de la Red Neuronal (MLP) para distintas combinaciones de arquitectura y tasa de aprendizaje. Las arquitecturas de dos capas obtienen los mejores resultados, con diferencias modestas entre configuraciones.

IV-B5. SVM: La SVM se implementó mediante LinearSVC con calibración probabilística vía Platt scaling (CalibratedClassifierCV), lo que permite escalar a los 350 000 ejemplos de entrenamiento sin submuestreo. Se evaluaron tres valores de $C \in \{0,1,10\}$. Como muestra la Fig. 5, el AUC en validación crece con C pero las diferencias son del orden de 10^{-6} , prácticamente despreciables. Este comportamiento indica que el modelo ha alcanzado su límite de capacidad: en una SVM lineal, C controla el balance entre margen y error de clasificación, pero cuando la frontera de decisión óptima es intrínsecamente no lineal —como en este problema— ningún valor de C puede compensar esa limitación estructural. El mejor modelo ($C = 10$) reportó AUC-CV de $0,684 \pm 0,002$, AUC de validación de 0.686 y AUC de prueba de 0.684, con F1 de 0.688 y *accuracy* de 0.642, resultados prácticamente idénticos a los de la Regresión Logística, lo cual es esperable: ambos modelos son clasificadores lineales y convergen al mismo techo de desempeño frente a relaciones no lineales complejas.




Figura 5. AUC-ROC en validación de la SVM (LinearSVC) en función del parámetro de regularización C . Las variaciones son del orden de 10^{-6} , lo que indica saturación de la capacidad del modelo lineal independientemente de la regularización.

IV-B6. XGBoost: XGBoost fue evaluado en una malla de $3 \times 3 \times 2 = 18$ combinaciones entre tasa de aprendizaje $lr \in \{0,05; 0,1; 0,2\}$, profundidad máxima $max_depth \in \{5; 8; 12\}$ y proporción de submuestreo de filas $subsample \in \{0,7; 1,0\}$, con parada temprana (*early stopping*) para determinar el número óptimo de iteraciones. La Fig. 6 muestra que los dos hiperparámetros más influyentes son la profundidad y la tasa de aprendizaje. La profundidad produce el mayor salto entre $depth=5$ y $depth=8$ (ganancia de $\approx 0,009$ puntos en AUC), mientras que la diferencia entre $depth=8$ y $depth=12$ es marginal ($< 0,002$), lo que indica que los árboles de profundidad 8 ya capturan la mayor parte de las interacciones relevantes. Por otro lado, tasas de aprendizaje bajas ($lr=0,05$) dominan consistentemente sobre valores más altos en todas las combinaciones de profundidad y submuestreo, lo que es coherente con el uso de *early stopping*: tasas menores permiten ajustes más finos antes de la parada. El efecto del submuestreo es menor, con $subsample=1,0$ ligeramente superior en las configuraciones de mayor profundidad. La mejor configuración ($lr=0,05$, $depth=12$, $subsample=1,0$) reportó AUC-CV de $0,823 \pm 0,004$, AUC de validación de 0.828 y AUC de prueba de 0.826, con F1 de 0.761 y *accuracy* de 0.744.




Figura 6. Búsqueda en malla de hiperparámetros para XGBoost. Cada celda muestra el AUC-ROC de validación para una combinación de tasa de aprendizaje (lr) y profundidad máxima (max_depth), separado por proporción de submuestreo ($subsample \in \{0,7, 1,0\}$).

IV-B7. LightGBM: LightGBM fue evaluado en una malla de $3 \times 4 \times 2 = 24$ combinaciones entre tasa de aprendizaje $lr \in \{0,05; 0,1; 0,2\}$, número de hojas $num_leaves \in \{31; 63; 127; 255\}$ y proporción de submuestreo $subsample \in \{0,7; 1,0\}$, con parada temprana para determinar el número óptimo de iteraciones. A diferencia de XGBoost, LightGBM crece los árboles por hoja (*leaf-wise*) en lugar de por nivel, por lo que num_leaves controla directamente la complejidad del modelo. La Fig. 7 muestra que el AUC mejora de forma notable al pasar de $num_leaves=63$ a 127 ($\approx +0,003$ puntos), mientras que la ganancia adicional de 127 a 255 es menor ($\approx +0,001$), lo que sugiere que 255 hojas captura interacciones que 127 no alcanza pero con rendimientos decrecientes. Los valores de $num_leaves=31$ y 63 resultan insuficientes para este problema. La tasa de aprendizaje sigue el mismo patrón que en XGBoost: $lr=0,05$ domina en todas las configuraciones. El $subsample$ no tuvo efecto alguno: los AUC son idénticos para $subsample=0,7$ y $1,0$ en todas las combinaciones. Esto no constituye un error metodológico sino un hallazgo genuino: con 315 000

muestras de entrenamiento, *early stopping* con 20 rondas y `feature_fraction=0,8`, el modelo dispone de suficiente regularización intrínseca, haciendo que el submuestreo adicional de filas sea redundante. LightGBM converge al mismo mínimo de validación con o sin él.




Figura 7. AUC-ROC en validación de LightGBM para distintas combinaciones de tasa de aprendizaje, número de hojas y submuestreo. El número de hojas es el hiperparámetro más influyente.

IV-B8. CatBoost: CatBoost fue evaluado en una malla de $3 \times 3 \times 3 = 27$ combinaciones entre tasa de aprendizaje $lr \in \{0,05; 0,1; 0,2\}$, profundidad $depth \in \{5; 8; 12\}$ y regularización $l2_leaf_reg \in \{1; 3; 10\}$, con parada temprana. La Fig. 8 muestra que la relación entre profundidad y tasa de aprendizaje no es independiente: con tasas bajas ($lr = 0,05$ y $0,1$), $depth = 12$ produce los mejores resultados (AUC = 0,8273 y 0,8269 respectivamente), pero con $lr = 0,2$ la ventaja se invierte y $depth = 8$ supera a $depth = 12$ (0,8261 frente a 0,8222). Esto sugiere que árboles más profundos requieren tasas de aprendizaje menores para converger correctamente con *early stopping*, pues de lo contrario sobreajustan antes de que la parada temprana actúe. $depth = 5$ queda consistentemente por debajo en casi todas las combinaciones, con la excepción de $lr = 0,2$ donde alcanza 0,8228, superando a $depth = 12$. El efecto de $l2_leaf_reg$ es secundario, lo cual es coherente con que *early stopping* ya provee regularización implícita. La mejor configuración ($lr = 0,05$, $depth = 12$, $l2_leaf_reg = 3$) reportó AUC-CV de $0,823 \pm 0,003$, AUC de validación de 0,827 y AUC de prueba de 0,825, con F1 de 0,761 y *accuracy* de 0,744.




Figura 8. AUC-ROC en validación de CatBoost (mejor $l2_leaf_reg$ por celda) para distintas combinaciones de tasa de aprendizaje y profundidad. Con tasas bajas $depth = 12$ domina, pero con $lr = 0,2$ la ventaja se invierte hacia $depth = 8$.

IV-B9. HistGradientBoosting: HistGradientBoosting fue evaluado en una malla de $3 \times 4 \times 2 = 24$ combinaciones entre tasa de aprendizaje $lr \in \{0,05; 0,1; 0,2\}$, número máximo de hojas $max_leaf_nodes \in \{31; 63; 127; \text{None}\}$ y regularización $l2_regularization \in \{0; 0,5\}$, con parada temprana. La Fig. 9 revela una interacción entre la complejidad del árbol y la regularización: sin regularización ($l2_reg = 0$), $max_leaf_nodes = \text{None}$ domina en todos los valores de lr , alcanzando el máximo de 0,8267 con $lr = 0,05$. Sin embargo, al agregar regularización ($l2_reg = 0,5$), la ventaja de la configuración irrestricta se reduce y $max_leaf_nodes = 127$ con $lr = 0,05$ (0,8242) se acerca a None con $lr = 0,1$ (0,8258), lo que sugiere que la penalización ℓ_2 compensa parcialmente el efecto de limitar la complejidad. En ambos paneles, $max_leaf_nodes = 31$ resulta insuficiente para este problema, con AUC consistentemente inferior a las demás configuraciones. La tasa de aprendizaje sigue el patrón observado en los demás modelos de boosting: valores bajos ($lr = 0,05$) producen mejores resultados en ausencia de regularización adicional. La mejor configuración ($lr = 0,05$, $max_leaf_nodes = \text{None}$, $l2_reg = 0$) reportó AUC-CV de $0,821 \pm 0,003$, AUC de validación de 0,826 y AUC de prueba de 0,825, con F1 de 0,760 y *accuracy* de 0,744.




Figura 9. AUC-ROC en validación de HistGradientBoosting para distintas combinaciones de tasa de aprendizaje y número máximo de hojas, con $l2_reg = 0$ (izquierda) y $l2_reg = 0,5$ (derecha). La configuración irrestricta de hojas sin regularización produce el mejor resultado global.

IV-B10. Stacking: El ensamble de *stacking* combina cinco modelos base (HistGB, XGBoost, LightGBM, CatBoost y Random Forest) con una Regresión Logística ($C = 1$) como meta-aprendiz, entrenada sobre las predicciones de probabilidad de los modelos base mediante validación cruzada interna con $k = 5$ pliegues para evitar fuga de información. Al no realizarse búsqueda en malla, cada modelo base fue configurado con los hiperparámetros de mejor desempeño identificados individualmente.

Como muestra la Fig. 10, el ensamble (AUC test = 0,825) supera a cuatro de los cinco modelos base, siendo XGBoost (0,823) el único que se acerca. La ganancia sobre los modelos base más débiles es notable: Random Forest (0,810) queda 1.5 puntos por debajo, y CatBoost (0,815) y HistGB (0,821) también son superados con claridad. Sin embargo, la mejora sobre XGBoost es marginal ($< 0,002$), lo que indica que cuando los modelos base son homogéneos en desempeño —como ocurre entre XGBoost, LightGBM y CatBoost— el meta-aprendiz tiene poco margen para extraer complementariedad adicional. La presencia de Random Forest como modelo base significativamente más débil introduce predicciones de menor

calidad que el meta-aprendiz debe aprender a ponderar, lo que podría estar limitando el potencial del ensamble. El ensamble reportó AUC-CV de $0,823 \pm 0,004$, AUC de validación de 0.827 y AUC de prueba de 0.825, con F1 de 0.760 y *accuracy* de 0.744.




Figura 10. AUC-ROC en prueba del ensamble *stacking* (5 modelos base + Regresión Logística) frente a cada modelo base individualmente. El ensamble supera a todos los modelos base excepto XGBoost, donde la ganancia es marginal.

IV-B11. Comparación Global: La Tabla III resume los resultados de todos los modelos evaluados. Los resultados revelan una estructura clara en tres grupos que refleja directamente la capacidad de cada familia de modelos para capturar la no linealidad del problema físico.

El grupo superior lo conforman la Red Neuronal (MLP) y los cuatro modelos de *gradient boosting* (XGBoost, CatBoost, HistGB y LightGBM), con AUC de prueba entre 0.824 y 0.826 y diferencias entre ellos menores a 0.002 —estadísticamente indistinguibles dada la variabilidad de los intervalos de confianza. Este techo de desempeño compartido tiene una interpretación física coherente: la tarea de separar eventos de señal y fondo en el dataset HIGGS está fundamentalmente limitada por el solapamiento intrínseco entre las distribuciones cinemáticas de ambos procesos, no por la capacidad del modelo. Las 28 variables disponibles, aunque diseñadas para maximizar la discriminación [3], no contienen información suficiente para separar perfectamente ambas clases, y todos los modelos suficientemente flexibles convergen al mismo límite práctico.

Dentro de este grupo, la MLP lidera en F1 (0.764) y *accuracy* (0.746), lo que sugiere que su frontera de decisión continua y diferenciable captura mejor las regiones de alta densidad de señal que los árboles, cuyas particiones por umbral producen fronteras discontinuas. El Stacking (0.825) no supera a XGBoost individualmente, confirmando lo observado en la Fig. 10: cuando los modelos base son homogéneos en desempeño, la combinación aporta poco.

Random Forest forma un segundo grupo claramente separado (AUC= 0,812), con una brecha de $\approx 0,013$ respecto al grupo superior. Esta diferencia refleja una limitación estructural: Random Forest construye árboles independientes sobre submuestras, mientras que *gradient boosting* construye árboles secuencialmente corrigiendo los errores del modelo anterior. En un problema donde la señal del bosón de Higgs se manifiesta como diferencias sutiles en combinaciones de variables de alto nivel —masas invariantes como m_{bb} y

m_{wbb} — la corrección iterativa del boosting es más efectiva que el promedio de árboles independientes.

El tercer grupo (KNN, Regresión Logística y SVM lineal, AUC entre 0.684 y 0.706) queda muy por debajo, lo que confirma que la frontera de decisión del problema es esencialmente no lineal. La similitud entre Regresión Logística (0.685) y SVM lineal (0.684) es esperable: ambos modelos imponen una frontera hiperplana en el espacio de entrada, y ninguno puede capturar las interacciones entre variables cinemáticas que caracterizan los eventos de señal. El KNN mejora modestamente (0.706) al aproximar la frontera de forma local, pero su capacidad está limitada por la maldición de la dimensionalidad en un espacio de 28 variables.

Cuadro III

COMPARACIÓN DE DESEMPEÑO DE TODOS LOS MODELOS EVALUADOS SOBRE LAS PARTICIONES DE ENTRENAMIENTO (CV), VALIDACIÓN Y PRUEBA. EL AUC-CV REPORTA LA MEDIA $\pm 2\sigma$ DE LA VALIDACIÓN CRUZADA CON $k = 5$.

Modelo	AUC-CV	AUC Val	AUC Test	F1 Test	Acc Test	Precision Test	Recall Test
Red Neuronal (MLP)	$0,820 \pm 0,006$	0.829	0.826	0.764	0.746	0.752	0.777
XGBoost	$0,823 \pm 0,004$	0.828	0.826	0.761	0.744	0.754	0.768
CatBoost	$0,823 \pm 0,003$	0.827	0.825	0.761	0.744	0.752	0.771
HistGradientBoosting	$0,821 \pm 0,003$	0.826	0.825	0.760	0.744	0.754	0.767
Stacking (5 base + LR)	$0,823 \pm 0,004$	0.827	0.825	0.760	0.744	0.754	0.767
LightGBM	$0,822 \pm 0,004$	0.826	0.824	0.760	0.744	0.754	0.766
Random Forest	$0,810 \pm 0,003$	0.814	0.812	0.751	0.734	0.746	0.757
KNN ($k = 25, 100K$)	$0,701 \pm 0,002$	0.704	0.706	0.701	0.652	0.644	0.770
Reg. Logística	$0,685 \pm 0,002$	0.687	0.685	0.688	0.643	0.640	0.743
SVM (linear)	$0,684 \pm 0,002$	0.686	0.684	0.688	0.642	0.640	0.743

Los intervalos de confianza son estrechos en todos los modelos ($\leq \pm 0,006$) y la consistencia entre AUC-CV, validación y prueba confirma ausencia de sobreajuste significativo. El intervalo más amplio corresponde a la MLP ($\pm 0,006$), lo que refleja la variabilidad inherente al entrenamiento con inicialización aleatoria, y no inestabilidad del modelo. Dado que MLP y XGBoost lideran en AUC de prueba y representan paradigmas fundamentalmente distintos —aprendizaje de representaciones continuas frente a ensamble de particiones discretas— se seleccionan como los dos mejores modelos para las etapas de reducción de dimensión.

V. REDUCCIÓN DE DIMENSIÓN

V-A. Análisis Individual de Variables

Se calcularon dos índices de discriminación para cada una de las 28 variables: la *Mutual Information* (MI) respecto a la etiqueta de clase y el *Fisher's Discriminant Ratio* (FDR). La MI cuantifica la dependencia estadística entre cada variable y la clase objetivo, mientras que el FDR mide la separación entre las medias de clase normalizada por la varianza intra-clase. Los rankings obtenidos se presentan en la Fig. 11.

Los resultados muestran que las variables de alto nivel (m_{bb} , m_{wbb} , m_{wbb} , m_{jlv} , m_{jjj}) concentran los mayores valores de MI y FDR, lo que es consistente con lo reportado por Baldi et al. [2], quienes señalan que estas características fueron diseñadas precisamente para maximizar la separación señal-fondo. En contraste, 19 de las 21 variables de bajo nivel presentan $MI < 0,01$, siendo candidatas a eliminación. Entre ellas se encuentran variables cinemáticas como $lepton_{pt}$, $missing_energy_magnitude$, los momentos transversos de los jets y los ángulos η y ϕ asociados.




Figura 11. Mutual Information y Fisher's Discriminant Ratio para cada una de las 28 variables, ordenadas de mayor a menor.

La matriz de correlación entre variables (Fig. 12) indica que las variables de bajo nivel presentan correlaciones bajas entre sí, mientras que las de alto nivel muestran correlaciones moderadas, lo cual es esperable dado que son combinaciones lineales derivadas de las primeras.




Figura 12. Matriz de correlación entre las 28 variables del dataset HIGGS.

Para complementar el análisis se calcularon el índice de discriminación d' y la correlación punto-biserial $|r_{pb}|$ (Fig. 13). El índice d' se define como $d' = |\mu_1 - \mu_0| / \sqrt{(\sigma_1^2 + \sigma_0^2)/2}$, donde μ_c y σ_c son la media y desviación estándar de la variable en la clase c . Ambos índices coinciden en señalar m_bb ($d' = 0,306$), m_wbbb ($d' = 0,247$) y $missing_energy_magnitudo$ ($d' = 0,201$) como las variables más discriminativas. En el extremo opuesto, los ángulos ϕ y η de los jets, junto con $lepton_phi$ y $missing_energy_phi$, presentan $d' < 0,003$ y p -valor $> 0,05$ en la prueba de correlación punto-biserial, lo que indica que su aporte discriminativo no es estadísticamente significativo.

Con base en el percentil 25 del índice d' como umbral de corte ($d' < 0,0028$), se eliminaron siete variables: $missing_energy_phi$, $jet1_eta$, $jet3_phi$, $jet1_phi$, $jet2_eta$, $jet3_eta$ y $lepton_phi$. Al re-evaluar los dos mejores modelos sobre el espacio reducido




Figura 13. Índice de discriminación d' (izquierda) y correlación punto-biserial $|r_{pb}|$ (derecha) para las 28 variables del dataset HIGGS. La línea punteada roja indica el umbral $d' = 0,1$.

de 21 variables (25 % de reducción), la degradación fue mínima: la Red Neuronal obtuvo AUC de prueba de 0.823 ($\Delta = -0,004$) y XGBoost de 0.824 ($\Delta = -0,002$), como se muestra en la Tabla IV. Esto confirma que las siete variables eliminadas aportan información marginal y pueden prescindirse sin pérdida significativa de desempeño.

Cuadro IV
COMPARACIÓN DEL AUC DE PRUEBA DE LOS DOS MEJORES MODELOS CON LAS 28 VARIABLES ORIGINALES Y CON LAS 21 VARIABLES SELECCIONADAS TRAS ELIMINAR AQUELLAS CON $d' < 0,0028$.

Modelo	Features	Reducción	AUC Test	ΔAUC
Red Neuronal (MLP) — Original	28	—	0.826	—
Red Neuronal (MLP) — Seleccionadas	21	25 %	0.823	-0.004
XGBoost — Original	28	—	0.826	—
XGBoost — Seleccionadas	21	25 %	0.824	-0.002

V-B. Extracción de Características Lineal (PCA)

Se aplicó Análisis de Componentes Principales (PCA) sobre las 28 variables originales estandarizadas. El criterio de selección del número de componentes fue retener el mínimo de componentes que expliquen al menos el 95 % de la varianza acumulada del conjunto de entrenamiento, criterio que equilibra compresión y preservación de información. El StandardScaler se ajustó exclusivamente sobre el conjunto de entrenamiento y se aplicó a validación y prueba para evitar fuga de información.

La Fig. 14 muestra la varianza explicada acumulada y la varianza individual por componente. Se necesitan **23 componentes** para alcanzar el 95.93 % de la varianza, reducción del 17.9 % respecto a las 28 variables originales. El panel derecho revela que ningún componente domina de forma aislada: el primero explica aproximadamente el 15 % de la varianza y la contribución decrece gradualmente, lo que indica que la información está distribuida entre muchas direcciones y no existe una proyección de baja dimensión que concentre la mayor parte de la varianza — explicando por qué son necesarios 23 componentes para alcanzar el umbral del 95 %.

Los dos mejores modelos fueron re-entrenados y evaluados sobre el espacio PCA de 23 componentes. Los resultados completos se presentan en la Tabla V. La Red Neuronal redujo su AUC de 0.826 a 0.787 ($\Delta = -0,039$) y XGBoost de 0.826 a 0.764 ($\Delta = -0,062$). El AUC-CV confirma la estabilidad de los resultados: $0,781 \pm 0,004$ para la Red




Figura 14. Varianza explicada acumulada en función del número de componentes PCA. La línea punteada indica el umbral del 95 %, alcanzado con 23 componentes.

Neuronal y $0,761 \pm 0,004$ para XGBoost, con diferencias menores a 0.006 respecto al AUC de prueba en ambos casos. La degradación más pronunciada en XGBoost es coherente con la naturaleza de los árboles de decisión: sus particiones explotan directamente las relaciones entre variables originales, y al operar sobre componentes PCA —combinaciones lineales de esas variables— pierden parte de esa estructura. La Red Neuronal, más robusta a transformaciones lineales del espacio de entrada, sufre menor pérdida.

Cuadro V

RESULTADOS DE LOS DOS MEJORES MODELOS CON PCA (23 COMPONENTES, 17.9 % DE REDUCCIÓN). EL AUC-CV CORRESPONDE A LA MEDIA $\pm 2\sigma$ DE VALIDACIÓN CRUZADA CON $k = 5$.

Modelo	AUC-CV	AUC Val	AUC Test	F1 Test	Acc Test	Recall Test
Red Neuronal (MLP) + PCA	$0,781 \pm 0,004$	0.789	0.787	0.733	0.714	0.742
XGBoost + PCA	$0,761 \pm 0,004$	0.766	0.764	0.726	0.698	0.755

V-C. Extracción de Características No Lineal (UMAP)

Se aplicó UMAP (*Uniform Manifold Approximation and Projection*) como técnica de extracción no lineal. Dado el costo computacional con 350 000 muestras, el reductor fue ajustado sobre una submuestra estratificada de 200 000 eventos de entrenamiento; los conjuntos de validación y prueba fueron transformados con el reductor ya ajustado, garantizando que no hubiera fuga de información. Los parámetros fijos fueron $n_neighbors = 15$ y $min_dist = 0,1$, valores estándar que balancean la preservación de estructura local y global.

El criterio de selección del número de componentes fue un barrido sobre $n_components \in \{2, 4, 8, 16\}$, evaluando el AUC de la Red Neuronal sobre el conjunto de validación (Fig. 15). El AUC crece monótonamente: 0.603, 0.624, 0.650 y 0.657 para 2, 4, 8 y 16 componentes respectivamente. Se seleccionaron **16 componentes** por ser la configuración que maximiza el AUC en validación, representando una reducción del 42.9 % respecto al espacio original.

La Tabla VI presenta los resultados completos sobre el espacio UMAP de 16 componentes. La Red Neuronal obtuvo AUC de prueba de 0.657 ($\Delta = -0,169$) y XGBoost de 0.650 ($\Delta = -0,176$). Los intervalos de confianza del AUC-CV ($0,662 \pm 0,003$ y $0,662 \pm 0,004$ respectivamente) muestran que ambos modelos tienen un desempeño similar en este espacio, y que la degradación es estable y no producto de variabilidad del entrenamiento. La Fig. 16 ilustra la proyección 2D: la amplia




Figura 15. AUC-ROC en validación de la Red Neuronal (MLP) en función del número de componentes UMAP. El AUC crece monótonamente; se seleccionan 16 componentes como mejor configuración evaluada.

superposición entre clases en ese espacio es consistente con la pérdida de información discriminativa observada.

Cuadro VI

RESULTADOS DE LOS DOS MEJORES MODELOS CON UMAP (16 COMPONENTES, 42.9 % DE REDUCCIÓN). EL AUC-CV CORRESPONDE A LA MEDIA $\pm 2\sigma$ DE VALIDACIÓN CRUZADA CON $k = 5$.

Modelo	AUC-CV	AUC Val	AUC Test	F1 Test	Acc Test	Recall Test
Red Neuronal (MLP) + UMAP	$0,662 \pm 0,003$	0.657	0.657	0.658	0.614	0.701
XGBoost + UMAP	$0,662 \pm 0,004$	0.653	0.650	0.658	0.610	0.707




Figura 16. Proyección 2D del espacio UMAP sobre 5000 eventos de entrenamiento, coloreados por clase (0=Fondo, 1=Señal). Aunque se aprecian clusters con predominancia de una clase, ambas clases aparecen mezcladas dentro de cada agrupación, lo que es consistente con la pérdida de información discriminativa observada al clasificar en este espacio.

V-D. Discusión y Conclusiones

La Tabla VII consolida los resultados de los dos mejores modelos bajo las cuatro representaciones evaluadas —espacio original, selección de variables, PCA y UMAP— y la Fig. 17 resume visualmente el impacto de cada técnica sobre el AUC de prueba.

Los resultados muestran que ninguna técnica de reducción mejora el AUC respecto al espacio original de 28 variables. La selección de variables basada en d' es la opción más eficiente:

Cuadro VII

COMPARACIÓN GLOBAL DE LOS DOS MEJORES MODELOS BAJO LAS CUATRO REPRESENTACIONES DEL ESPACIO DE ENTRADA EVALUADAS.

Modelo	Espacio	Dim.	Reducción	AUC Test	Δ AUC	Acc Test
Red Neuronal (MLP)	Original	28	—	0.826	—	0.746
Red Neuronal (MLP)	Sel. variables	21	25.0 %	0.823	−0.004	—
Red Neuronal (MLP)	PCA	23	17.9 %	0.787	−0.039	0.714
Red Neuronal (MLP)	UMAP	16	42.9 %	0.657	−0.169	0.614
XGBoost	Original	28	—	0.826	—	0.744
XGBoost	Sel. variables	21	25.0 %	0.824	−0.002	—
XGBoost	PCA	23	17.9 %	0.764	−0.062	0.698
XGBoost	UMAP	16	42.9 %	0.650	−0.176	0.610




Figura 17. AUC-ROC en prueba de la Red Neuronal (MLP) y XGBoost bajo los tres espacios de representación principales: variables originales, PCA (23 componentes) y UMAP (16 componentes).

eliminar las 7 variables menos discriminativas reduce el espacio un 25 % con una pérdida de solo $\Delta = -0,002$ en XGBoost y $\Delta = -0,004$ en la Red Neuronal, prácticamente despreciable. PCA ofrece un compromiso aceptable con 17.9 % de reducción y pérdidas de entre 0.039 y 0.062 en AUC. UMAP, pese a alcanzar la mayor reducción (42.9 %), produce una degradación inaceptable ($\Delta \approx -0,17$), lo que sugiere que sus proyecciones —optimizadas para visualización— no preservan suficientemente la información discriminativa a esta escala.

Este comportamiento es coherente con la naturaleza del dataset: las 28 variables del HIGGS fueron diseñadas por físicos para maximizar la discriminación entre señal y fondo [2], por lo que comprimir cualquier subconjunto conlleva pérdida de información relevante. La baja redundancia lineal del dataset —solo 5 componentes prescindibles en PCA al 95 % de varianza— respalda esta interpretación.

En comparación con la literatura, los resultados sobre el espacio original (AUC = 0,826) superan los reportados por Azhari et al. [1] (AUC $\approx 0,705$ con *gradient boosted trees* en PySpark) y son competitivos con los de Baldi et al. [2] (AUC $\approx 0,880$ con redes profundas sobre 10.5 millones de eventos). La diferencia respecto a Baldi et al. se explica por el menor tamaño de entrenamiento empleado (350 000 frente a ~ 10.5 millones de eventos) y la mayor complejidad arquitectural de las redes profundas de ese trabajo. En condiciones de cómputo comparables a las del presente proyecto, los modelos evaluados alcanzan un desempeño razonable y coherente con el estado del arte.

El mejor sistema identificado es la Red Neuronal (MLP) con arquitectura (128, 64) y $\text{lr} = 0,001$, entrenada sobre las 28 variables originales, con AUC-ROC de 0.826 en el conjunto de prueba. Si se requiere reducción dimensional, la selección de las 21 variables con mayor d' es la alternativa más recomen-

dable, con una pérdida mínima de desempeño ($\Delta = -0,004$) y una reducción del 25 % en la dimensionalidad del espacio de entrada.

VI. CONCLUSIONES

El problema de clasificación señal-fondo en el dataset HIGGS reproduce, en escala reducida, uno de los retos centrales de la física de partículas de alta energía: distinguir colisiones en las que se produce un bosón de Higgs de aquellas que corresponden a procesos de fondo del Modelo Estándar, a partir exclusivamente de variables cinemáticas medidas en el detector. La partícula de interés no se observa directamente —decae casi instantáneamente— y solo deja trazas en sus productos de desintegración. Esta naturaleza indirecta del problema impone una frontera de decisión inherentemente no lineal, hecho que los resultados de este trabajo confirman de manera consistente: los modelos lineales (Regresión Logística y SVM) alcanzan AUC $\approx 0,685$, mientras que los modelos capaces de capturar relaciones no lineales (MLP, XGBoost, CatBoost, HistGB, LightGBM) convergen alrededor de AUC $\approx 0,826$, una brecha de 0.14 puntos que no puede atribuirse a diferencias de regularización o ajuste de hiperparámetros, sino a la capacidad estructural del modelo.

El análisis de discriminación de variables reveló que las cinco variables de alto nivel (m_{bb} , m_{wwbb} , m_{wbb} , m_{jlv} , m_{jjj}) concentran la mayor parte de la información discriminativa, lo cual tiene una interpretación física directa: estas masas invariantes fueron construidas por físicos para reconstruir los estados intermedios de la cadena de desintegración del bosón de Higgs (el bosón W leptónico, el sistema W +jet y los estados $b\bar{b}$), capturando así la dinámica de la producción. En contraste, los ángulos η y ϕ de los jets y del leptón, así como el ángulo ϕ de la energía transversa faltante, presentan índices de discriminación $d' < 0,003$ estadísticamente no significativos. Esta redundancia informativa de los ángulos es coherente con la naturaleza del problema: en colisiones de alta energía, la distribución angular de los productos de desintegración es aproximadamente isotrópica en el plano transversal, por lo que estas variables no distinguen bien entre señal y fondo.

La eliminación de las siete variables angulares menos discriminativas (reducción del 25 % en dimensionalidad) produjo una pérdida mínima de desempeño — Δ AUC = $-0,002$ en XGBoost y $-0,004$ en la Red Neuronal—, lo que indica que las variables eliminadas son efectivamente redundantes y que la información discriminativa relevante está contenida en las variables cinemáticas de momento transversal y en las masas invariantes de alto nivel. Esta conclusión tiene implicaciones prácticas: en un experimento real, prescindir de variables que no aportan discriminación reduce el costo computacional del clasificador sin comprometer su capacidad de separación señal-fondo.

Las técnicas de extracción de características (PCA y UMAP) degradaron significativamente el desempeño: PCA con 23 componentes produjo Δ AUC $\approx -0,04$ y UMAP con 16 componentes generó una caída de Δ AUC $\approx -0,17$. Este resultado refleja que la información discriminativa está

distribuida entre múltiples variables de forma no redundante: las 28 variables del dataset fueron diseñadas precisamente para maximizar la separación señal-fondo [2], por lo que cualquier proyección que mezcle o comprima ese espacio destruye parte de la estructura física capturada. La selección quirúrgica de variables —conservar aquellas con mayor poder discriminativo— es sustancialmente superior a la reducción dimensional no supervisada para este tipo de datos físicos.

En comparación con la literatura, el mejor resultado obtenido ($AUC = 0,826$) supera ampliamente lo reportado por Azhari et al. [1] ($AUC \approx 0,705$ con *gradient boosted trees* en PySpark) y se aproxima razonablemente a los resultados de Baldi et al. [2] ($AUC \approx 0,885$ con redes profundas de cinco capas sobre 10.5 millones de eventos). La brecha de 0.059 puntos respecto a Baldi et al. es atribuible principalmente al volumen de entrenamiento: este trabajo utilizó 350 000 muestras frente a los ~ 10.5 millones del trabajo original —menos del 5 % de los datos disponibles—, además de no emplear arquitecturas profundas especializadas ni técnicas de aumento de datos. Que modelos de *gradient boosting* clásicos alcancen $AUC = 0,826$ con recursos de cómputo limitados los posiciona como una alternativa competitiva y eficiente como línea base sólida para este problema.

En síntesis, el clasificador recomendado es XGBoost entrenado sobre las 21 variables seleccionadas ($AUC = 0,824$, $\Delta = -0,002$ respecto al espacio completo), por su equilibrio entre desempeño, interpretabilidad y eficiencia computacional. Si se requiere el máximo desempeño sin restricciones de dimensionalidad, la Red Neuronal MLP con arquitectura (128, 64) y $lr = 0,001$ sobre las 28 variables originales constituye la mejor opción evaluada ($AUC = 0,826$). En ambos casos, la reducción PCA o UMAP no se recomienda para este dataset dado el costo discriminativo que implica.

REFERENCIAS

- [1] Mourad Azhari, Abdallah Abarda, Badia Ettaki, Jamal Zerouaoui, and Mohamed Dakkon. Higgs boson discovery using machine learning methods with pyspark. *Procedia Computer Science*, 170:1141–1146, 2020.
- [2] Pierre Baldi, Peter Sadowski, and Daniel Whiteson. Searching for exotic particles in high-energy physics with deep learning. *Nature Communications*, 5:4308, 2014.
- [3] Hmida Hmida, Sana Ben Hamida, Amel Borgi, and Marta Rukoz. Scale genetic programming for large data sets: Case of higgs bosons classification. *Procedia Computer Science*, 126:302–311, 2018.
- [4] Daniel Whiteson. Higgs. UCI Machine Learning Repository, 2014.